






一. 机器学习视角下的强化学习


步骤一. 学习函数(网络)



步骤二. 定义 "Loss"



步骤三. 优化




轨迹 $\tau = \{s_1, a_1, s_2, a_2, \dots\}$

问题: ① Action 是采样得到的, 具有随机性

② Env. 和 Reward 是黑盒模型, 具有随机性.

二. Policy Gradient

1. 如何控制你的 Actor



接受动作 $\hat{a}$: Loss $L = e$

不接受动作 $\hat{a}$: Loss $L = -e$

优化目标: $\theta^* = \arg\min_{\theta} L$

若对于观测 s_1 有 Loss e_1 , s_2 有 Loss $-e_2$, 则 $L = e_1 - e_2$

训练数据

$\{s_1, \hat{a}_1\} \rightarrow A_1 + 0.5$

$\{s_2, \hat{a}_2\} \rightarrow A_2 - 0.5$

$\{s_3, \hat{a}_3\} \rightarrow A_3 + 0.5$

...

$\{s_N, \hat{a}_N\} \rightarrow A_N - 10.0$

Total Loss:

$$\Rightarrow L = \sum A_n e_n$$

2. 训练数据的由来

Version 0:

记录 Actor 在环境中的每一步, 记录环境的观测 s 和 Actor 的动作 a , 我们给“观测-动作”对打分 A .

好的打正分, 坏的打负分

$$\text{RP } \{s_t, a_t\} \rightarrow A_t = r_t$$

缺点:

(1) t 时刻的动作 a_t 会影响下一时刻的环境, 从而影响下一时刻的观测 s_{t+1} 和动作 a_{t+1} .

仅靠 t 时刻的 $\{s_t, a_t\}$ 得到 A_t 显然是不妥的.

(2) **Reward Delay**: Actor 可以通过牺牲当前的 reward r_t 以获得长程的 reward $r_{t'}$.

以坦克大战为例, 在 Version 0 数据集中, 由于只有“开火”会获得分数, 因此坦克只学会了“开火”.

Version 1:

$$\{s_1, \hat{a}_1\} \rightarrow r_1 \rightarrow A_1 = G_1 = r_1 + r_2 + r_3 + \dots + r_N$$

$$\{s_2, \hat{a}_2\} \rightarrow r_2 \rightarrow A_2 = G_2 = r_2 + r_3 + \dots + r_N$$

$$\{s_3, \hat{a}_3\} \rightarrow r_3 \rightarrow A_3 = G_3 = r_3 + \dots + r_N$$

...

$$\{s_N, \hat{a}_N\} \rightarrow r_N \rightarrow A_N = G_N = r_N$$

累计回报 (cumulated reward): $G_t = \sum_{n=t}^N r_n$

Version 2:

累计回报 2 (cumulated reward): $G'_t = r_t + \gamma r_{t+1} + \gamma^2 r_{t+2} + \dots$
$$= \sum_{n=t}^N \gamma^{n-t} r_n$$

其中 γ 为折扣系数

Version 3:

$$G''_t = G'_t - b$$

Baseline: 一个常数, 用于标准化

3. Policy Gradient

① 初始化 Actor 网络参数 θ

② 训练从 $i = 1$ 到 T 进行迭代


(1) 使用 Actor θ^{i-1} 进行交互

(2) 获得数据 $\{s_1, a_1\}, \{s_2, a_2\}, \dots, \{s_N, a_N\}$

(3) 计算 $A_1, A_2, \dots, A_N$

(4) 计算 Loss L

(5) $\theta^i \leftarrow \theta^{i-1} - \eta \nabla L$



不断收集数据

不断训练

4. on-policy vs off-policy

On-policy: 用于训练的 Actor 和用于交互的 Actor 是同一个

Off-policy: 用于训练的 Actor 和用于交互的 Actor 是不一样的

5. Exploration

有些动作 Actor 从来没有采取过, 该怎么让 Actor 探索呢?


(1) 加大输出的 Entropy (有更大概率采样到没执行过的动作)

(2) 在参数中添加随机噪声.

三. Actor - Critic

Critic: 给定 actor θ , 在观测到 s (和动作 a) 可能会得到多少 r

Value function $V^\theta(s)$: 当使用 actor θ 时, 在观测到 s 后期望得到的 discounted cumulated reward $G_t = r_t + \gamma r_{t+1} + \gamma^2 r_{t+2} + \dots$



1. 如何评估 $V^\theta(s)$


a. 蒙特卡罗 (Monte - Carlo, MC) 方法

critic 观测 actor θ 与环境进行交互.

在观测到 S_a 后,

直到 episode 的末尾, 得到


cumulated reward 为 G_a



b. 时序差分 (Temporal - difference, TD) 方法

$$\left. \begin{aligned} V^\theta(S_t) &= r_t + \gamma r_{t+1} + \gamma^2 r_{t+2} + \dots \\ V^\theta(S_{t+1}) &= r_{t+1} + \gamma r_{t+2} + \dots \end{aligned} \right\} \Rightarrow V^\theta(S_t) = \gamma V^\theta(S_{t+1}) + r_t$$

在观测到 - 组序列 $\dots S_t, a_t, r_t, S_{t+1}, \dots$



c. MC v.s. TD

critic 观测到 8 段 episode: (假设 $\gamma = 1$)

(1) $S_a, r=0, S_b, r=0, \text{END}$

(2) $S_b, r=0, \text{END}$

(3) $S_b, r=0, \text{END}$

(4) $S_b, r=0, \text{END}$

(5) $S_b, r=0, \text{END}$

(6) $S_b, r=0, \text{END}$

$$V^\theta(S_b) = \frac{3}{4}$$

$$\text{MC: } V^\theta(S_a) = 0$$


$$\text{TD: } V^\theta(S_a) = \frac{3}{4}$$

(7) $S_b, r=0, \text{END}$



(8) $S_b, r=0, \text{END}$

2. 训练数据 注意这里是 Actor 的训练资料


Version 3.5: $G''_t = G'_t - V^\theta(S_t)$



Version 4: $A_t = \cancel{G'_t - V^\theta(S_t)} = r_t + V^\theta(S_{t+1}) - V^\theta(S_t)$



3. Actor - Critic 训练技巧



四. Reward shaping

1. sparse reward

假设 Reward r_t 几乎都是零, 我们就无法得知动作的好坏。(下围棋)



定义额外的 reward (reward shaping)

① 自定义的 reward shaping

例如在一款射击游戏中定义:

动作	reward
闲逛	-0.04
射击	-0.05
损失生命	-0.04
回复生命	0.08

...

② 基于好奇心 (curiosity) 的 reward shaping

当 **agent** 看到新东西的时候, 获得额外的 **reward**


例如超级马里奥为了不断能看到新东西, 就会不停向右走.

五. 逆向强化学习 (Inverse RL): 如何从范式中学习

1. 动机 (无 reward 的动机)

现实中可能无法很好的定义 reward.

2. 模仿学习



① Actor 与环境 Environment 互动, 但不获得 reward.

② 学习专家 expert 与环境 Environment 的交互示范

(1) 专家 expert (通常是人类) 与环境 Environment 的交互集合

$$\{\tau_1, \tau_2, \dots, \tau_k\}$$

其中 τ_i 是某个专家与环境交互的轨迹


(2) 行为克隆 (Behavior Cloning)

$$\text{expert} : \tau = \{s_1, \hat{a}_1, s_2, \hat{a}_2, \dots\}$$


$$\text{actor} : s_i \rightarrow \text{actor} \rightarrow a_i \xleftarrow{\text{监督}} \hat{a}_i$$

3. 逆向强化学习 (Inverse RL) (IRL)

正向:



逆向:



Expert

原则：老师的行为永远是最好的

基本思想：

a. 初始化一个 actor

b. 在每次迭代中

(1) actor 与环境 Env. 交互获得一些轨迹 τ

(2) 定义 reward function, 使得老师的轨迹 $\hat{\tau}$ 优于 actor 的轨迹

(3) actor 通过学习来最大化 reward, 基于新的 reward function

IRL 的架构

