


- Q-learning 概述

① 状态-动作值函数 $Q^\pi(s, a)$

定义：当使用 actor π 时，在采取动作 a 和状态 s 后期望得到的 cumulated reward。



② Q-learning 流程



给定 $Q^\pi(s, a)$ ，找到一个新的 actor π' (比 π “好”)，
其中“好”的定义为 $V^{\pi'}(s) \geq V^\pi(s)$ ，对于所有状态 s ：

$$\pi'(s) = \underset{a}{\operatorname{argmax}} Q^\pi(s, a)$$

证明：对于所有 s ， $V^{\pi'}(s) \geq V^\pi(s)$

$$V^\pi(s) = Q^\pi(s, \pi(s)) \leq \max_a Q^\pi(s, a) = Q^\pi(s, \pi'(s))$$

$$V^\pi(s) \leq Q^\pi(s, \pi'(s))$$

$$= E[r_t + V^\pi(S_{t+1}) | S_t = s, a_t = \pi'(s_t)]$$

$$\leq E[r_t + Q^\pi(S_{t+1}, \pi'(S_{t+1})) | S_t = s, a_t = \pi'(s_t)]$$

$$= E[r_t + r_{t+1} + V^\pi(S_{t+2}) | \dots]$$

$$\leq E[r_{t+1} + r_{t+2} + Q^\pi(S_{t+2}, \pi'(S_{t+2})) | \dots] \dots$$


$$\leq V^{\pi'}(s)$$

③ Tips: Target Network

时序差分思想:

$$\dots, S_t, a_t, r_t, S_{t+1}, \dots$$

$$Q^\pi(S_t, a_t) = r_t + Q^\pi(S_{t+1}, \pi(S_{t+1}))$$




④ Exploration

(1) No exploration

策略 π 是基于 Q -function 的:

$$a = \arg \max_a Q(s, a)$$

问题




(2) Epsilon Greedy ϵ 在学习时会 decay

$$a = \begin{cases} \arg \max_a Q(s, a) & , \text{ 概率为 } 1 - \epsilon \\ \text{随机} & , \text{ 概率为 } \epsilon \end{cases}$$

(3) 波尔兹曼 Exploration

$$P(a|s) = \frac{\exp(Q(s, a))}{\sum_a \exp(Q(s, a))}$$

⑥ Replay Buffer



⑥ 典型 Q-learning 算法

a. 初始化 Q-function Q 和目标 Q-function $\hat{Q} = Q$

b. 在每一个 episode 中

(1) 对每一个 step t .

1. 给定 s_t , 基于 Q (epsilon greedy) 采取 a_t

2. 得到 r_t 并到达 s_{t+1}

3. 将 $\{s_t, a_t, r_t, s_{t+1}\}$ 存入 buffer

4. 从 buffer 中采样 $\{s_i, a_i, r_i, s_{i+1}\}$ (通常为一个 batch)

5. 目标 $y = r_i + \max_a \hat{Q}(s_{i+1}, a)$

6. 更新 Q 的参数使得 $Q(s_i, a_i)$ 接近 y (回归)

7. 经 C 步后重置 $\hat{Q} = Q$


二、一些 Advanced Tips

① Double DQN

问题: Q-value 常常 over estimate

$$Q(s_t, a_t) \longleftrightarrow r_t + \max_a Q(s_{t+1}, a)$$

倾向于选择 over-estimated 的动作



Double DQN: 两个 Q-function Q 和 Q' (Target Network)

$$Q(s_t, a_t) \longleftrightarrow r_t + Q'(s_{t+1}, \arg\max_a Q(s_{t+1}, a))$$

(1) 如果 Q 高估了 a , 则 a 会被选择, 但 Q' 会正确估计其 value

(2) 如果 Q' 高估了动作 a , 该动作不会被 Q 选择.

?

...

三. 连续动作的 Q-learning


Action a 是一个连续向量

$$a = \arg\max_a Q(s, a)$$


解决办法 1 采样一组动作 $\{a_1, a_2, \dots, a_n\}$

解决办法 2. 利用梯度上升解决优化问题 (a 相当于训练参数)

解决办法 3. 设计一个网络



$$Q(s, a) = - (a - \mu(s))^T \Sigma(s) (a - \mu(s)) + V(s)$$



解决办法 4 不使用 Q-learning